

2026APMCM B 题 问题一解答

一、数据集规模

本地统计结果显示，肺部 CT 数据集共包含 1000 张图片，其中训练集 613 张、验证集 72 张、测试集 315 张。

划分	图片数	占比
训练集	613	61.30%
验证集	72	7.20%
测试集	315	31.50%
合计	1000	100.00%

二、类别分布

四类样本总计分别为腺癌 338 张、大细胞癌 187 张、正常 215 张、鳞状细胞癌 260 张。整体来看，数据并非严格等量，但类别分布仍处于可控范围，属于中度不均衡。

类别	训练集	验证集	测试集	总计	总体占比
腺癌	195	23	120	338	33.80%
大细胞癌	115	21	51	187	18.70%
正常	148	13	54	215	21.50%
鳞状细胞癌	155	15	90	260	26.00%

三、分层抽样模型

设总体样本数为 N ，第 k 个子集样本数为 N_k ，第 c 类总体样本数为 N_c ，则简单分层抽样可写为 $n_{\{k,c\}} = \text{round}\left(\frac{N_k \times N_c}{N}\right)$ 。

若四类原始样本数量均等，则 $N_c = \frac{N}{4}$ ，此时 $n_{\{k,c\}} \approx \frac{N_k}{4}$ ，意味着每个子集都应尽量保持相同的类别比例。

四、均衡性判断与训练影响

从当前划分看，训练集、验证集和测试集都保留了四类样本，且比例趋势与总体分布一致，因此可以视为近似均衡的分层划分，而不是严格等量划分。

这种划分能降低训练集与验证/测试集之间的分布偏移，使模型评估更稳定；但验证集仅 72 张，波动会更明显，后续建模仍需关注少数类召回与类别不平衡问题。

结论：当前数据划分方式总体合理，适合用于后续分类模型训练与评估。