

B题 肺癌疾病诊断图像识别与分类问题

肺癌是全球发病率与死亡率位居前列的恶性肿瘤，早期病灶特征隐蔽，临床确诊多依赖肺部 CT 影像人工阅片。传统人工诊断高度依赖医师临床经验，大批量 CT 影像筛查易出现视觉疲劳、漏诊、误诊等问题，且基层医疗机构专业影像医师资源短缺，难以满足大规模人群肺癌早筛需求。随着人工智能、深度学习图像识别技术快速发展，基于医学 CT 影像的智能辅助诊断模型，成为提升肺癌筛查效率、统一诊断标准、实现早发现早治疗的重要手段。



图1. 患者的肺部医疗扫描影像图。

本次竞赛配套专用肺部 CT 影像数据集，包含高分辨率肺部扫描图像，将样本划分为腺癌、大细胞癌、正常肺部组织、鳞状细胞癌四大类别，并按照 613 张训练集、72 张验证集、315 张测试集完成分层划分，完整覆盖模型训练、参数调优与泛化能力测试全流程数据需求。依托该标准化标注数据集，通过数学统计建模分析数据分布特征，结合计算机视觉算法构建多分类识别预测模型，能够自动区分健康肺部与不同类型肺癌病灶，量化模型诊断精度，为临床肺癌影像智能辅助诊断提供可落地的算法方案，同时也为医学影像识别、疾病预测相关数学建模与大模型应用研究提供标准化实验载体。

现有肺部 CT 影像数据集用于肺癌智能辅助诊断，数据集共分为训练集、验证集、测试集三部分，影像分为四类标签：1-腺癌、2-大细胞癌、3-正常肺部、4-鳞状细胞癌。各数据集图片数量：训练集 613 张、验证集 72 张、测试集 315 张。现需结合数学建模与图像深度学习模型完成肺部病灶分类识别与预测分析。

数据说明：

类别：腺癌、大细胞癌、正常、鳞状细胞癌（4 分类）

训练集：613 张；验证集：72 张；测试集：315 张

问题1（数学建模统计分析）

1. 计算整套肺部 CT 数据集总图片数量；
2. 分别计算训练集、验证集、测试集图片占全部数据集的比例（保留 2 位小数）；
3. 若采用分层抽样方式划分数据集，假设四类肺部影像原始样本数量均等，建立简单分层抽样分配模型，说明该数据集划分方式是否均衡，并简述对模型训练效果的影响。

问题2（图像识别预测建模）

基于 CT 影像四分类识别任务，搭建图像分类预测模型完成肺癌诊断：

1. 说明训练集、验证集、测试集在模型训练、调参、效果评估中的各自作用；
2. 模型完成训练后，使用 315 张测试集图片进行预测，定义分类准确率作为评价指标，给出准确率计算公式；若模型正确识别 279 张测试影像，计算该模型肺癌 CT 影像识别准确率（保留 2 位小数）；
3. 结合四类影像识别任务，简述如何优化模型，降低腺癌、鳞状细胞癌两类癌症样本的误诊概率。

作品提交

(1). /src 目录：该目录下为所有算法和模型的程序代码文件、保存的图片、文本和表格等文件，必须包含 main.py 文件和求解所有问题的源代码文件；

(2). /doc 目录：撰写程序代码的说明文档，以便评审老师理解算法和运行代码。

评价方式

赛题成绩由图片鉴别准确率决定(鉴别结果无法识别或输出不全的，视为错误)。准确度相同的，以运行时间少的为优，运行时间也相同的，以提交时间早的为优。源代码无法运行或无法正确输出结果文件的，均视为无效提交。